

Tout savoir sur la régression logistique

Partie 2



Présenté par **Morgan Gautherot**



Problème de classification




	Nb d'e-mails ouverts (x_1)	Nb de produits achetés (x_2)	Panier moyen (x_3)	Ouverture de l'e- mail (y)
1	12	3	120	1
2	0	1	40	0
3	30	10	1800	1
4	14	5	799	1
...
m	25	2	260	0

Jeu d'entraînement pour la prédiction de prix de maison

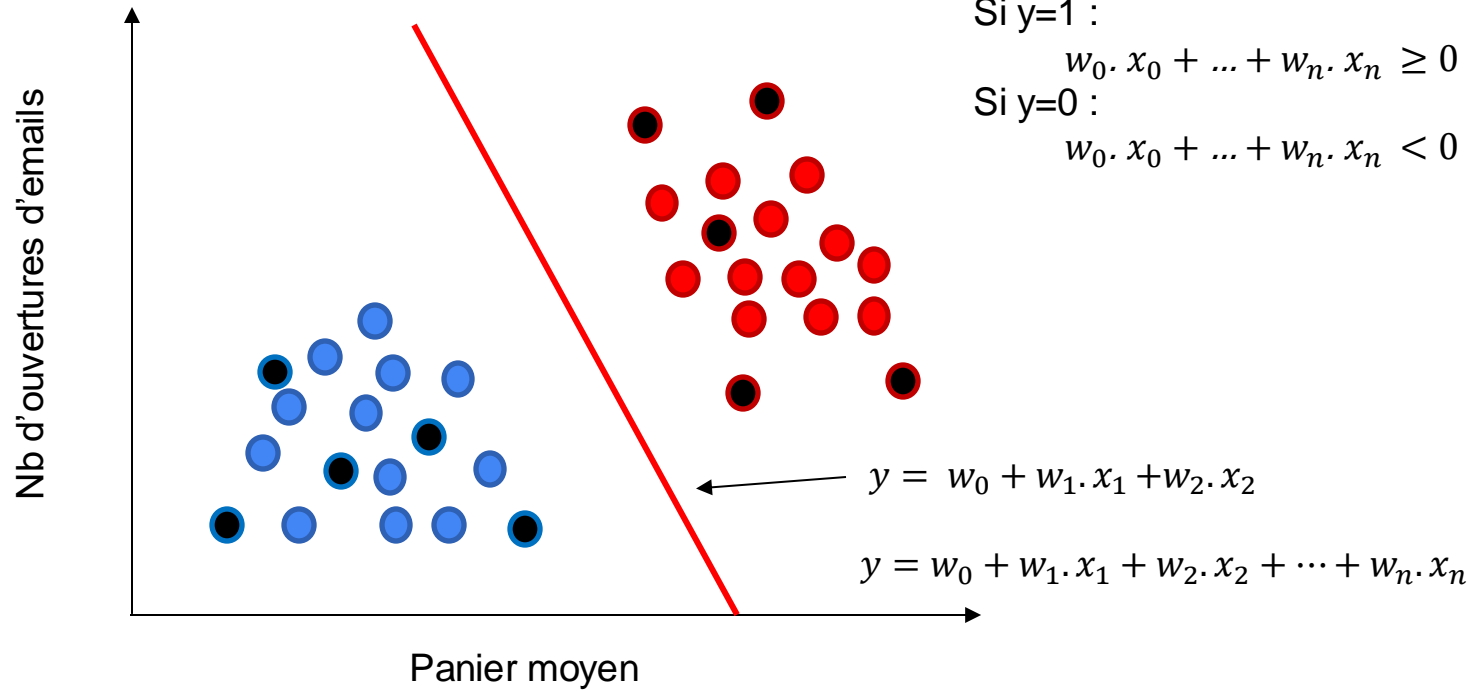


Utiliser une droite





Utiliser une droite





Similitude avec la régression linéaire


- Nous voulons une ligne séparant nos deux classes.
- Pour cela, nous utiliserons donc l'équation de la régression linéaire :

$$\hat{y} = w_0 \cdot x_0 + w_1 \cdot x_1 + w_2 \cdot x_2 + \dots + w_n \cdot x_n$$

- Pour la régression linéaire $\hat{y} \in R$
- Pour la régression logistique $0 \leq \hat{y} \leq 1$



La fonction sigmoïde



$$g(z) = \frac{1}{1+e^{-z}}$$

$$0 \leq g(z) \leq 1$$



Expression du modèle

- Cette fonction prend en entrée les variables et retourne une valeur entre 0 et 1.

$$\hat{y} = g(W^T X) = \frac{1}{1 + e^{-W^T X}}$$



- Plus \hat{y} est proche de 1, plus l'observation a de chance d'appartenir à la classe 1.
- Plus \hat{y} est proche de 0, plus l'observation a de chance d'appartenir à la classe 0.



Une fonction de coût de la régression linéaire

$$\min J(W) = \frac{1}{2m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2$$



$$\min J(W) = \frac{1}{2m} \sum_{i=1}^m \left(\frac{1}{1+e^{-w^T x^{(i)}}} - y^{(i)} \right)^2$$





Fonction convexe pour la classification

$$\text{Coût}(\hat{y}, y) = \begin{cases} -\log(\hat{y}) & \text{si } y = 1 \\ -\log(1 - \hat{y}) & \text{si } y = 0 \end{cases}$$





Fonction de coût pour la régression logistique

$$\text{Coût}(\hat{y}, y) = \begin{cases} -\log(\hat{y}) & \text{si } y = 1 \\ -\log(1 - \hat{y}) & \text{si } y = 0 \end{cases}$$

$$\text{Coût}(\hat{y}, y) = -y \log(\hat{y}) - (1 - y) \log(1 - \hat{y})$$

Si $y = 1$

$$\text{Coût}(\hat{y}, y) = -1 \log(\hat{y})$$

Si $y = 0$

$$\text{Coût}(\hat{y}, y) = -1 \log(1 - \hat{y})$$

$$\min J(W) = \frac{1}{m} \sum_{i=1}^m -y^{(i)} \log(\hat{y}^{(i)}) - (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$$



Le gradient descent

Répéter jusqu'à la convergence {

$$w_j := w_j - \alpha \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) \cdot x_j^{(i)} \text{ (simultanément } j = (0, \dots, n)$$

}