

# Tout savoir sur la régression pénalisée

## Partie 3



Présenté par **Morgan Gautherot**

# **A. Pénalisation de la fonction de coût**






# Sur-entraînement et sous-entraînement

## Sous-entraînement

Erreur sur le jeu d'entraînement : Élevée


Erreur sur le jeu de test : Élevée



## Entraînement correct

Erreur sur le jeu d'entraînement : Faible


Erreur sur le jeu de test : Faible



## Sur-entraînement

Erreur sur le jeu d'entraînement : Nulle


Erreur sur le jeu de test : Moyenne






## Complexité du modèle

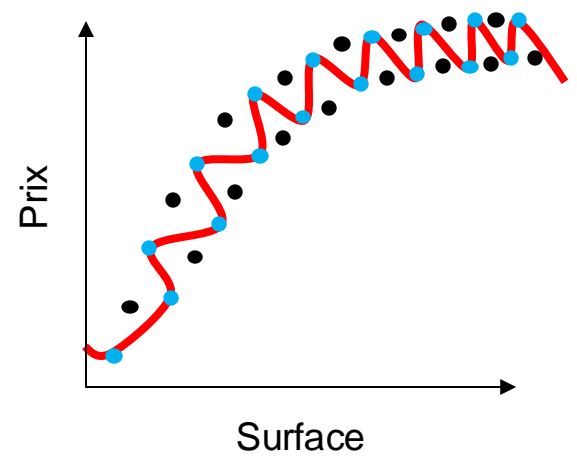
$$\hat{y} = w_0 + w_1 \cdot x_1$$



$$\hat{y} = w_0 + w_1 \cdot x_1 + w_2 \cdot x_1^2$$



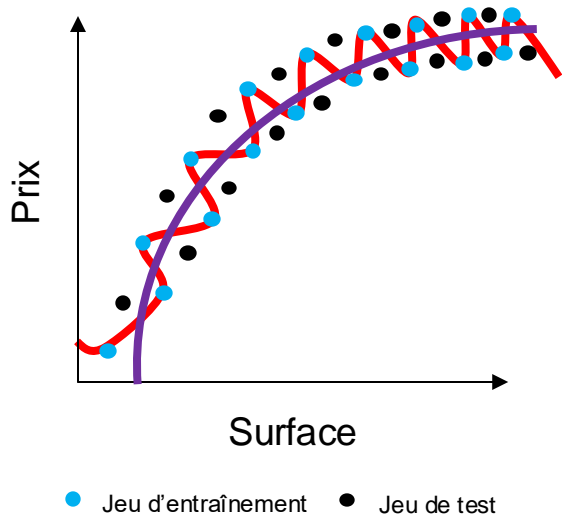
$$\hat{y} = w_0 + w_1 \cdot x_1 + w_2 \cdot x_1^2 + w_3 \cdot x_1^3 + w_4 \cdot x_1^4 + \dots$$



● Jeu d'entraînement    ● Jeu de test



## Pénalisation des paramètres



$$\hat{y} = w_0 + w_1 \cdot x_1 + w_2 \cdot x_1^2 + w_3 \cdot x_1^3 + w_4 \cdot x_1^4 + \dots$$

Pénalisation des paramètres

$$\min_w J(w) = \underbrace{\frac{1}{2m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2}_{\text{Minimiser l'erreur de prédiction}} + \underbrace{1000 \cdot w_3 + 1000 \cdot w_4 + \dots}_{\text{Minimiser la valeur des paramètres } w_3, w_4, \dots}$$

Minimiser l'erreur  
de prédiction

Minimiser la valeur des  
paramètres  $w_3, w_4, \dots$

## **B. La régression Lasso**





## Régression Lasso ou pénalisation L1

- Un modèle plus simple avec moins de paramètres est moins sujet au sur-entraînement.

Paramètre de régularisation

$$J(w) = \frac{1}{2m} \left[ \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2 + \lambda \sum_{j=1}^n |w_j| \right]$$



Régularisation



## Impact du coefficient de régularisation

$\lambda$  trop petit

$$J(w) = \frac{1}{2m} \left[ \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2 + \lambda \sum_{j=1}^n |w_j| \right]$$









## Impact du coefficient de régularisation

$\lambda$  trop grand

$$J(w) = \frac{1}{2m} \left[ \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2 + \lambda \sum_{j=1}^n |w_j| \right]$$







## Impact du coefficient de régularisation

[0.01, ..., 0.1, ..., 0.5]

↖  
 **$\lambda$  adéquat**

$$J(w) = \frac{1}{2m} \left[ \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2 + \lambda \sum_{j=1}^n |w_j| \right]$$



## C. La régression Ridge





## Régression Ridge ou pénalisation L2

- Un modèle avec des paramètres plus homogène est moins sujet au sur-entraînement.

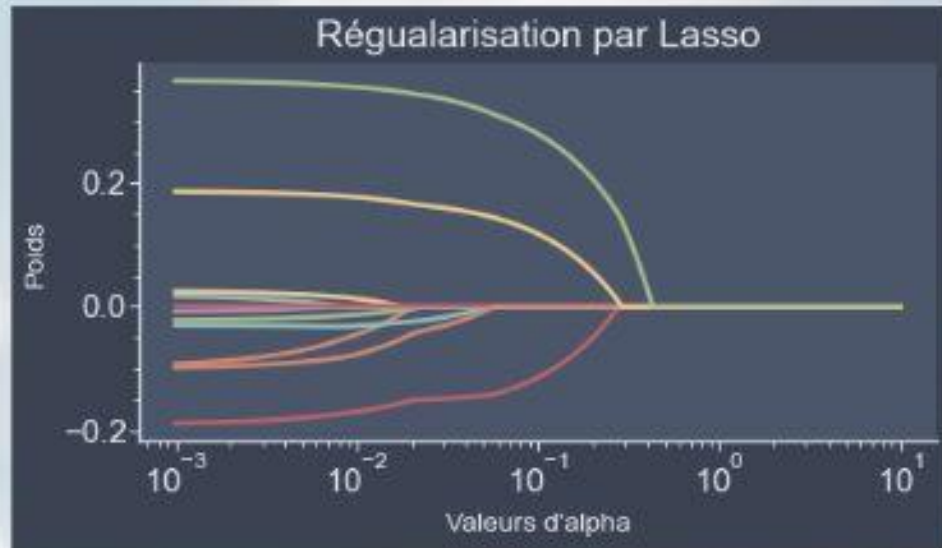
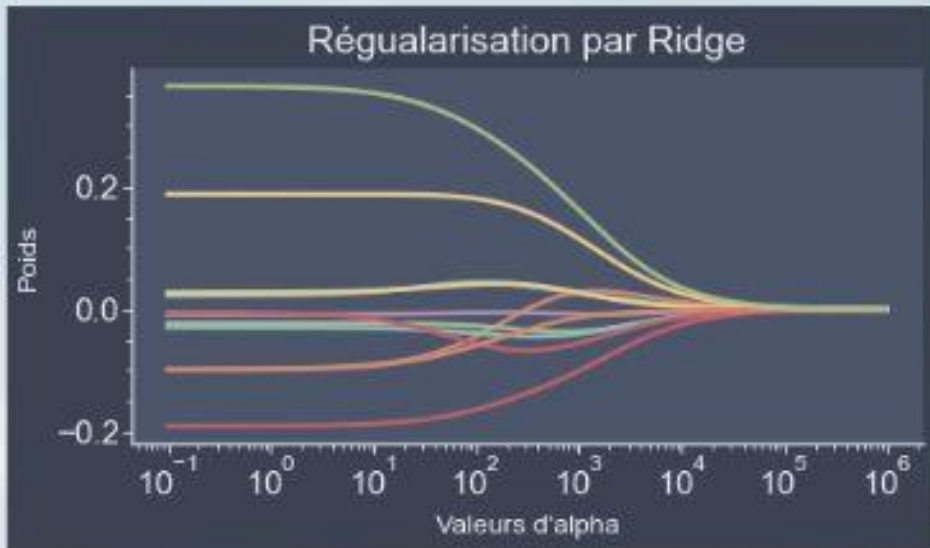
Paramètre de régularisation

$$J(w) = \frac{1}{2m} \left[ \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2 + \lambda \sum_{j=1}^n w_j^2 \right]$$

Régularisation



## Lasso vs Ridge



## D. La régression Elasticnet





## Régression Elasticnet ou régularisation L1 et L2

Paramètre de régularisation

$$J(w) = \frac{1}{2m} \left[ \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda_1 \sum_{j=1}^n |w_j| + \lambda_2 \sum_{j=1}^n w_j^2 \right]$$

Paramètre de régularisation

$$J(w) = \frac{1}{2m} \left[ \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda \left[ \alpha \sum_{j=1}^n |w_j| + \frac{1-\alpha}{2} \sum_{j=1}^n w_j^2 \right] \right]$$

Mix entre la régularisation L1 et L2



## Régression Elasticnet ou régularisation L1 et L2

$\alpha = 0$

$$J(w) = \frac{1}{2m} \left[ \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda \left[ \alpha \sum_{j=1}^n |w_j| + \frac{1 - \alpha}{2} \sum_{j=1}^n w_j^2 \right] \right]$$

L2

$\alpha = 1$

$$J(w) = \frac{1}{2m} \left[ \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda \left[ \alpha \sum_{j=1}^n |w_j| + \frac{1 - \alpha}{2} \sum_{j=1}^n w_j^2 \right] \right]$$

L1




## **E. Pour la régression logistique**







## Pour la classification



Sous-entraînement



Entraînement correct



Sur-entraînement



## Régression logistique pénalisée

Ridge

$$J(w) = - \left[ \frac{1}{m} \sum_{i=1}^m y^{(i)} \log(h(x^{(i)})) + (1 - y^{(i)}) \log(1 - h(x^{(i)})) \right] + \frac{\lambda}{2m} \sum_{j=1}^n w_j^2$$

Lasso

$$J(w) = - \left[ \frac{1}{m} \sum_{i=1}^m y^{(i)} \log(h(x^{(i)})) + (1 - y^{(i)}) \log(1 - h(x^{(i)})) \right] + \frac{\lambda}{2m} \sum_{j=1}^n |w_j|$$

Elasticnet

$$J(w) = - \left[ \frac{1}{m} \sum_{i=1}^m y^{(i)} \log(h(x^{(i)})) + (1 - y^{(i)}) \log(1 - h(x^{(i)})) \right] + \lambda \left[ \alpha \sum_{j=1}^n |w_j| + \frac{1 - \alpha}{2} \sum_{j=1}^n w_j^2 \right]$$



## Résumé

---

- Lasso/pénalisation L1
  - Sélection des variables les plus importantes
- Ridge/pénalisation L2
  - Homogénéisation des paramètres
- Elasticnet/pénalisation L1 & L2
  - Sélection des variables et homogénéisation des paramètres.